

Redes Neuronales Guiadas por Física para la Estimación de Parámetros Estelares desde Espectros $H\alpha$: Cerrando la Brecha del Dominio Sintético-Observado en Estrellas Masivas

Santiago Anwandter
Universidad Técnica Federico Santa María
Valparaíso, Chile
santiago.anwandter@usm.cl

Benjamín Cisternas
Universidad Técnica Federico Santa María
Valparaíso, Chile
benjamin.cisternas@usm.cl



Abstract

Estimar los parámetros estelares de estrellas masivas a partir de líneas espectrales $H\alpha$ es una tarea crítica para comprender la evolución estelar. Los modelos de aprendizaje automático entrenados en grandes grillas de espectros sintéticos logran un rendimiento sólido dentro de la distribución, pero se degradan severamente al aplicarse a espectros reales observados, un fenómeno conocido como la *brecha sintética*. Proponemos abordar esta limitación incorporando una restricción suave basada en física en la función de pérdida de entrenamiento, derivada de la prescripción autoconsistente de tasa de pérdida de masa de Figueroa-Tapia et al. [5]. Nuestra hipótesis es que penalizar predicciones físicamente inconsistentes durante el entrenamiento reducirá los errores fuera de distribución en observaciones reales sin requerir datos pareados sintético-observados. Validamos esta hipótesis en tres niveles: el error in-distribution sobre una partición sintética de prueba, la coherencia distribucional contra espectros UVES POP sin etiquetas, y el error puntual fuera de distribución contra las etiquetas parciales de literatura de estrellas de tipo O de los catálogos IACOB [4, 7]. El término físico reduce el error medio absoluto de T_{eff} sobre estrellas reales de $\sim 10\,300$ a $\sim 3\,500$ K y revierte un sesgo sistemático de $+10\,000$ K —recolocando las predicciones dentro del régimen físico admisible—, confirmando la hipótesis sin emplear datos observados etiquetados durante el entrenamiento.

CCS Concepts

• Computing methodologies → Neural networks.

Keywords

physics-guided machine learning, massive stars, $H\alpha$, synthetic gap, domain adaptation

1 Introducción

Las estrellas masivas gobiernan la evolución química de las galaxias a través de poderosos vientos impulsados por radiación y supernovas de colapso de núcleo. Caracterizar sus parámetros de tasa de pérdida de masa $\dot{M}$ y parámetros atmosféricos como temperatura efectiva T_{eff} , gravedad superficial $\log g$ es esencial para modelos evolutivos precisos [5]. La línea $H\alpha$ es el diagnóstico espectroscópico principal para los parámetros de viento en supergigantes de tipo O, ya que la forma de su perfil es directamente sensible tanto a la velocidad terminal del viento v_{∞} como a la propia tasa de pérdida de masa $\dot{M}$ [9].

Trabajos recientes han demostrado que el aprendizaje automático puede estimar los parámetros estelares a partir de perfiles $H\alpha$. Ortiz et al. [9] desarrollaron un pipeline de múltiples etapas que combina agrupamiento por Gaussian Mixture Models, clasificación por redes neuronales profundas y deconvolución espectral entrenado en la base de datos sintética ISOSCELES [9], logrando inferencia en menos de un segundo y superando el ajuste de expertos para 9 de las 12 supergigantes de tipo B evaluadas. Sin embargo, un desafío fundamental permanece sin resolver: los modelos entrenados completamente en espectros sintéticos típicamente fallan al generalizarse a observaciones reales. Esta es la *brecha sintética*, una discrepancia sistemática entre perfiles de líneas teóricos y observados que surge de las suposiciones simplificadoras en los modelos de atmósfera, efectos instrumentales y ruido observacional [10]. La Figura 1 ilustra esta discrepancia a nivel de perfil espectral: el perfil sintético es sistemáticamente más profundo y suave que su contraparte observada.

La consecuencia es que un regresor entrenado en la grilla ISOSCELES produce estimaciones de parámetros físicamente implausibles al evaluarse en espectros estelares observados. Las predicciones




Figure 1: Brecha sintético–observado en $H\alpha$. Perfil sintético ISOSCELES (azul) frente a su contraparte observada de IACOB (rojo, HD 41997), ambos con parámetros próximos ($T_{\text{eff}} \approx 35\,900\text{ K}$, $\log g \approx 3.66$). El núcleo sintético es más profundo y carece del ensanchamiento, *veiling*, asimetría y ruido —incluidas líneas metálicas— presentes en la observación. La augmentación (verde) cierra parte de la brecha pero no su totalidad, motivando la restricción física.

caen fuera de la región físicamente admisible del espacio de parámetros, haciendo al modelo poco confiable para datos reales. Esto motiva la pregunta central de este trabajo.

Pregunta de Investigación. ¿Puede un modelo de machine learning entrenado exclusivamente con espectros de $H\alpha$ sintéticos generalizar de forma físicamente consistente a espectros observados de estrellas masivas de tipo O, si se incorpora una restricción física teórica autoconsistente en la función de pérdida? Precisamos el sentido operacional de *físicamente consistente*: medimos dos propiedades verificables —que las predicciones caigan dentro del rango admisible del régimen O y que se corrija el sesgo sistemático respecto a las etiquetas de literatura— sin afirmar por ello una mejora en la exactitud por estrella individual.

Hipótesis. Una red neuronal entrenada en perfiles $H\alpha$ sintéticos con un término de pérdida física auxiliar que penaliza desviaciones de la prescripción autoconsistente de pérdida de masa de Figueroa-Tapia et al. [5] producirá predicciones de parámetros estelares que sean más consistentes físicamente y generalicen mejor a espectros observados de *estrellas masivas de tipo O* que una línea de base puramente basada en datos entrenada con los mismos datos sintéticos, incluso sin acceso a etiquetas observadas durante el entrenamiento.

Esta hipótesis es directamente comprobable: la restricción física es una ecuación algebraica que relaciona tres de las cuatro salidas predichas por nuestro modelo $\{T_{\text{eff}}, \log g, R_*\}$ con la cuarta, $\dot{M}$ (ver §3.1), y puede evaluarse tanto en entradas sintéticas como observadas sin ningún dato adicional etiquetado. Adicionalmente, disponemos de etiquetas de literatura parciales del proyecto IACOB: Holgado et al. [7] proporcionan T_{eff} , $\log g$ y R_* para 358 estrellas de tipo O, mientras que de Burgos et al. [4] proporcionan T_{eff} y $\log g$ para 527 estrellas O y B tempranas; tras aplicar el filtro de validez FT26 (§3.2) conservamos únicamente el subconjunto O. Esto permite una evaluación OOD con métricas de error directo (MAE, RMSE, sesgo).

Relevancia e Impacto

Impacto científico. La brecha sintética en espectroscopía estelar limita la explotación de grandes surveys fotométricos y espectroscópicos (GAIA, SDSS, VLT-FLAMES) para estudios de población de estrellas masivas. Si una restricción física autoconsistente permite reducir el error de dominio sin requerir datos pareados sintético-observados, se elimina un cuello de botella fundamental en la caracterización de vientos estelares. Por ejemplo, censos de estrellas O como el VLT-FLAMES Tarantula Survey o el propio proyecto IACOB —hoy dependientes de ajuste manual estrella a estrella— podrían procesarse de forma homogénea y rápida, habilitando estudios poblacionales de la relación viento–metalicidad. Esto impacta directamente modelos de evolución estelar, síntesis de poblaciones y retroalimentación química en simulaciones cosmológicas.

Impacto social y tecnológico. Las estrellas masivas son los principales productores de elementos pesados y radiación ionizante; comprender sus parámetros de viento es esencial para modelar la habitabilidad planetaria y la evolución galáctica. Desde una perspectiva de machine learning, este trabajo ofrece un caso de estudio sobre cómo integrar conocimiento científico de primer principio en redes neuronales profundas cuando los datos etiquetados del dominio objetivo son inexistentes, una situación común en astrofísica, geofísica e ingeniería.

Beneficiarios. La comunidad de astrofísica estelar obtiene una herramienta de inferencia rápida y físicamente consistente; la comunidad de ML recibe una demostración de *physics-guided deep learning* en un régimen de cambio de dominio severo donde las técnicas estándar de adaptación de dominio no aplican por ausencia de datos observacionales etiquetados.

Reproducibilidad. Código, resultados y modelos entrenados disponibles en <https://github.com/sanwandter/pgnn-stellar-parameter>.

2 Related Work

2.1 Neural Networks para la Estimación de Parámetros Estelares desde $H\alpha$

Ortiz et al. [9] es el predecesor más directo de este trabajo y emplea la misma infraestructura de datos. Su método de múltiples etapas utiliza perfiles $H\alpha$ sintéticos de la grilla ISOSCELES de soluciones de viento m-CAK δ -slow para entrenar un clasificador de red neuronal profunda que asigna un perfil espectral observado a uno de 21 grupos. Una comparación χ^2 posterior dentro del grupo predicho identifica el modelo de mejor ajuste. El método es objetivo, rápido y mejora el ajuste manual para la mayoría de su muestra de supergigantes B.

Ortiz et al. sí evalúan el método en espectros observados, pero *sin adaptación explícita al cambio de dominio*: la evaluación se realiza en estrellas con parámetros estelares *conocidos a priori* de estudios anteriores, proporcionando una cota superior de factibilidad. La pregunta de qué sucede cuando el modelo se aplica sin conocimiento previo, en el régimen fuera de distribución, no se aborda. Los autores reconocen que 3 de las 12 estrellas arrojaron ajustes insatisfactorios, y que el método no estima incertidumbres de parámetros desde un punto de vista estadístico, reservando las redes neuronales bayesianas para trabajo futuro.

Nuestro trabajo extiende esta línea de investigación apuntando explícitamente al fallo de generalización: en lugar de aceptar la brecha sintética como una limitación, proponemos reducirla mediante entrenamiento informado por física.

2.2 La Brecha Sintética en Espectroscopía Estelar

O’Brian et al. [10] proporcionan la caracterización más rigurosa de la brecha sintética en el contexto de la espectroscopía estelar. Su método Cycle-StarNet aplica adaptación de dominio no supervisada basada en redes generativas antagónicas y representaciones latentes compartidas para transferir modelos sintéticos de Kurucz al dominio observacional de APOGEE (Apache Point Observatory Galactic Evolution Experiment). Demuestran que incluso con una lista de líneas mejorada, los modelos Kurucz crudos producen un residuo normalizado considerable contra las observaciones de APOGEE, que Cycle-StarNet logra reducir drásticamente, alcanzando una mejora sustancial en el χ^2_R reducido.

Es importante destacar que el enfoque de adaptación de dominio de Cycle-StarNet es completamente basado en datos: requiere grandes conjuntos de datos observados no etiquetados y no codifica explícitamente física de vientos estelares o atmósfera. Esto es a la vez una fortaleza (no se necesita conocimiento del dominio) y una limitación: no hay garantía de que las predicciones adaptadas al dominio caigan dentro del espacio de parámetros físicamente admisible, particularmente para tipos estelares fuera de distribución. Además, Cycle-StarNet fue diseñado para la estimación de abundancias en estrellas de tipo solar; su aplicabilidad a estrellas masivas con perfiles H α complejos formados por vientos no ha sido demostrada.

La comprensión central de [10] para nuestro trabajo es el diagnóstico preciso del problema: la brecha sintética en H α para estrellas masivas probablemente está impulsada por la misma combinación de aproximaciones del modelo y efectos instrumentales identificados para estrellas más frías, y debe abordarse en lugar de asumirse inexistente.

2.3 Physics informed neural networks

Von Rueden et al. [12] proporcionan el marco conceptual para nuestra solución propuesta a través de una taxonomía exhaustiva del aprendizaje automático informado. Definen el *Informed machine learning* como el aprendizaje a partir de una fuente de información híbrida de datos y conocimiento previo, donde el conocimiento previo se integra explícitamente en el pipeline de aprendizaje. Entre las estrategias de integración identificadas, incorporar física en forma de *ecuaciones algebraicas en el algoritmo de aprendizaje mediante términos de pérdida basados en conocimiento* representa el enfoque dominante para el conocimiento científico. Esta estrategia de agregar un término de penalización $\lambda_k \mathcal{L}_k(f(\mathbf{x}_i), \mathbf{x}_i)$ a la pérdida estándar se ha aplicado en dominios que van desde la dinámica de fluidos hasta la predicción de temperatura del agua, donde consistentemente mejora la generalización y asegura la consistencia con las leyes físicas conocidas.

Masclans et al. [8] proporcionan una prueba de concepto directa en un problema de regresión termofísica análogo. Su Red Neuronal Informada por Termodinámica (TINN) reconstruye campos

de temperatura y densidad a partir de datos de velocidad de flujos turbulentos supercríticos mediante la incorporación de la ecuación de estado de gas real como término de penalización suave en la función de pérdida. Su resultado clave es que en el escenario de generalización difícil (Caso II: datos de entrenamiento y prueba de instantáneas temporalmente distantes con diferentes perfiles termofísicos), la línea de base ANN puramente basada en datos se degrada significativamente, mientras que TINN recupera los perfiles correctos para la región de pared caliente. La restricción física proporciona la regularización necesaria para permanecer en la variedad físicamente admisible cuando la distribución de entrada cambia, exactamente el papel que buscamos para el cambio de dominio sintético-real en espectroscopía H α .

Tanto [12] como [8] establecen que los términos de pérdida informados por física son más efectivos precisamente en el régimen de datos limitados o cambio distribucional, que caracteriza nuestro problema.

2.4 PINNs en Astrofísica Estelar

Ballester et al. [1] presentan la primera demostración de un marco PINN auto-supervisado para las ecuaciones de estructura estelar, combinando pérdidas basadas en las ecuaciones diferenciales de equilibrio hidrostático y térmico con redes auxiliares diferenciables para la ecuación de estado y la opacidad. El modelo produce perfiles radiales continuos de presión, temperatura, densidad y luminosidad sin requerir datos de entrenamiento etiquetados, alcanzando un error relativo medio de 3.06% y $R^2 = 0.9998$ frente a soluciones de referencia del código MESA.

El resultado clave de [1] para nuestro trabajo es su estudio de ablación sobre el papel de la restricción física. Los autores comparan tres configuraciones con la misma arquitectura: (a) entrenamiento puramente supervisado en datos MESA sin pérdida física, logrando MRAE = 3.85%; (b) entrenamiento supervisado con pérdida física incorporada, logrando 2.05%; y (c) entrenamiento auto-supervisado sin datos, usando únicamente la pérdida física, logrando 3.06%. La incorporación de la restricción física reduce el error en un 47% respecto al modelo puramente basado en datos, y elimina oscilaciones no físicas en las predicciones. Los autores concluyen explícitamente que los enfoques de ML supervisado para modelado estelar “heredan sesgos de las simulaciones subyacentes y no generalizan de forma fiable más allá de su dominio de entrenamiento” [1], diagnóstico que es análogo al problema de la brecha sintética que motiva nuestro trabajo.

Nuestro enfoque difiere del de [1] en tres dimensiones. Primero, Ballester et al. abordan el *problema directo*: dadas las condiciones de frontera, resolver la estructura interna de la estrella; nosotros abordamos el *problema inverso*: dado un espectro observado, inferir los parámetros superficiales. Segundo, su restricción física consiste en residuos de PDEs evaluados mediante autodiferenciación; la nuestra es una relación algebraica cerrada derivada de la prescripción de pérdida de masa CNO, que no requiere derivadas de la red respecto a las entradas. Tercero, su marco es completamente auto-supervisado (sin etiquetas); el nuestro combina supervisión sobre la grilla sintética con una restricción física que actúa como regularizador de dominio. Esta distinción es deliberada: disponemos de etiquetas sintéticas de alta calidad y el objetivo no es reemplazar

el solver, sino reducir la degradación al pasar de espectros sintéticos a observados.

2.5 Prescripciones Autoconsistentes de Pérdida de Masa para Estrellas Masivas

Figueroa-Tapia et al. [5] derivan prescripciones teóricas de tasa de pérdida de masa para estrellas de tipo O a través de una metodología autoconsistente que acopla la hidrodinámica del viento m-CAK con cálculos detallados de aceleración de líneas de radiación. Su hallazgo clave es que la prescripción de Vink et al. [11] de uso común sobreestima las tasas de pérdida de masa porque subestima la dilución del flujo UV causada por líneas metálicas. Su prescripción de grilla-CNO, ajustada mediante regresión lineal bayesiana con $R^2 = 0.929$, relaciona $\dot{M}$ directamente con los parámetros estelares observables:

$$\log \dot{M}_{\text{FT26}} = (-20.74 \pm 0.61) + (1.44 \pm 0.09) \log \left(\frac{R_*}{R_\odot} \right) - (3.85 \pm 0.15) \log g + (16.81 \pm 0.45) \log \left(\frac{T_{\text{eff}}}{1000 \text{ K}} \right), \quad (1)$$

con $R^2 = 0.929$ sobre la muestra de ajuste de Figueroa-Tapia et al. [5].

Esta relación algebraica es precisamente el tipo de conocimiento científico identificado por [12] como más naturalmente representado e integrado como una restricción en la función de pérdida. Dado que la relación involucra solo cantidades predichas por nuestro modelo (T_{eff} , $\log g$, R_* , $\dot{M}$), no se necesitan entradas adicionales. La restricción es diferenciable con respecto a todas las salidas predichas y puede retropropagarse directamente.

2.6 Brecha de Investigación

Hasta donde sabemos, ningún trabajo previo ha combinado restricciones físicas de la teoría de vientos estelares con el entrenamiento de redes neuronales para reducir la brecha sintético-observado específicamente para la estimación de parámetros $H\alpha$ en estrellas masivas. Ortiz et al. [9] operan completamente dentro del dominio sintético; O'Briain et al. [10] usan adaptación de dominio sin física; Masclans et al. [8] y Ballester et al. [1] usan restricciones físicas en dominios distintos al nuestro, termodinámica de fluidos y estructura estelar interna, respectivamente, y ninguno aborda el problema inverso de estimación de parámetros superficiales desde espectros $H\alpha$ bajo cambio de dominio sintético-real.

3 Metodología

3.1 Notación y formulación del problema

Sea un espectro estelar en la región $H\alpha$ —definida como la ventana [6542.8, 6582.8] Å (± 20 Å en torno a la línea $H\alpha$, 6562.8 Å)—muestreado en $N = 200$ puntos equiespaciados ($\Delta\lambda \approx 0.2$ Å/px), representado como un vector de flujo normalizado $\mathbf{x} \in \mathbb{R}^N$. Los espectros observados provienen de instrumentos de alta resolución ($R \gtrsim 40\,000$; FIES, FEROS, HERMES, UVES) y se degradan a esta grilla común mediante el re-muestreo. El objetivo es predecir un vector de parámetros estelares $\mathbf{y} = [T_{\text{eff}}, \log g, \log \dot{M}, R_*]^\top \in \mathbb{R}^4$, donde T_{eff} es la temperatura efectiva, $\log g$ la gravedad superficial,

$\log \dot{M}$ el logaritmo de la tasa de pérdida de masa, y R_* el radio estelar.

Denotamos el conjunto de entrenamiento sintético como $\mathcal{D}_{\text{syn}} = \{(\mathbf{x}_i, \mathbf{y}_i)\}_{i=1}^{N_{\text{syn}}}$, donde las etiquetas $\mathbf{y}_i$ provienen de la grilla ISOSCELES de modelos de viento m-CAK δ -slow. El conjunto de evaluación observacional, sin etiquetas de entrenamiento, es $\mathcal{D}_{\text{obs}} = \{\mathbf{x}_j\}_{j=1}^{N_{\text{obs}}}$, correspondiente a espectros de la encuesta ESO UVES POP.

Dado que los rangos de los parámetros difieren en órdenes de magnitud, aplicamos una normalización Min-Max a cada componente:

$$\tilde{y}_k = \frac{y_k - y_k^{\min}}{y_k^{\max} - y_k^{\min}}, \quad k \in \{T_{\text{eff}}, \log g, \log \dot{M}, R_*\}, \quad (2)$$

donde $y_k^{\min}$ y $y_k^{\max}$ se computan exclusivamente sobre $\mathcal{D}_{\text{syn}}$: $T_{\text{eff}} \in [30\,000, 45\,000]$ K, $\log g \in [3.15, 3.90]$, $\log \dot{M} \in [-10.47, -5.25]$ y $R_* \in [7.02, 20.93]$ $R_\odot$. Estos mismos rangos se emplean para desnormalizar las predicciones antes de evaluar $\mathcal{L}_{\text{phys}}$ en espacio físico (§3.4).

3.2 Datos y preprocesamiento

Table 1: Conjuntos de datos efectivamente utilizados. N : número de espectros. ISOSCELES es el subconjunto de tipo O no-rotante válido bajo los rangos FT26 de la grilla completa (342 779). IACOB fusiona los catálogos de Holgado2025 y de Burgos2024 tras el filtro de validez FT26 (184/522 estrellas; 148 con R_*).

Conjunto	N	Etiquetas	Uso
ISOSCELES (sint.)	33 444	$T_{\text{eff}}, \log g, \log \dot{M}, R_*$	Entren./Valid./Test
UVES POP O (obs.)	12	Ninguna	Eval. OOD distribucional (W_1)
IACOB (filtro FT26)	184	$T_{\text{eff}}, \log g; R_*$ (148)	Eval. OOD puntual

Espectros sintéticos (ISOSCELES). La grilla ISOSCELES [9] contiene 342 779 espectros $H\alpha$ sintéticos generados mediante el código de transferencia radiativa FASTWIND acoplado con soluciones hidrodinámicas m-CAK δ -slow, cubriendo rangos de temperatura efectiva T_{eff} , gravedad superficial $\log g$, tasa de pérdida de masa $\log \dot{M}$ y radio estelar R_* . De esta grilla seleccionamos el subconjunto de 33 444 espectros de tipo O no-rotantes cuyos parámetros caen dentro de los rangos de validez de la prescripción FT26, sobre el que se realiza la partición de entrenamiento, validación y prueba.

Espectros observacionales sin etiquetas (ESO UVES POP). Utilizamos espectros de estrellas masivas de la biblioteca espectral ESO UVES Paranal Observatory Project, observados con el espectrógrafo UVES del VLT. Se seleccionan estrellas con tipos espectrales O. El preprocesamiento es idéntico al sintético: recorte a la región $H\alpha$, re-muestreo a $N = 200$ puntos mediante interpolación lineal, y normalización. Este conjunto se utiliza exclusivamente para evaluación distributiva OOD, sin etiquetas de parámetros estelares.

Espectros observacionales con etiquetas (IACOB). El proyecto IACOB provee dos catálogos complementarios de parámetros espectroscópicos:

Holgado et al. [7] analizan 358 estrellas galácticas de tipo O combinando espectroscopía de alta resolución con paralajes Gaia DR3 y fotometría multibanda. Reportan T_{eff} , gravedad superficial $\log g$, radio estelar R_* , entre otros. Los instrumentos principales son FIES (Nordic Optical Telescope), FEROS (MPG/ESO 2.2m) y HERMES.

De Burgos et al. [4] analizan 527 estrellas OB luminosas galácticas con FASTWIND, reportando T_{eff} , $\log g$, y el parámetro de fuerza de viento $\log Q = \log[\dot{M}/(v_{\infty} R_*)^{3/2}]$.

Filtro de validez FT26. Para que la evaluación puntual se realice dentro del régimen de validez de la prescripción CNO, restringimos la muestra IACOB combinada a estrellas con $T_{\text{eff}} \in [30\,000, 50\,000]$ K, $\log g \in [2.9, 4.3]$ y, cuando R_* está disponible, $R_* \in [7, 70] R_{\odot}$. De las 522 estrellas con espectro H α válido, 184 superan el filtro y constituyen el conjunto de evaluación puntual; 148 de ellas disponen de R_* . Estos rangos coinciden con los empleados para definir la tasa de predicciones fuera de rango físico (§3.6).

Todos los espectros IACOB se preprocesan siguiendo el mismo pipeline que los datos sintéticos: recorte a la región H α , re-muestreo a $N = 200$ puntos, y normalización. Este conjunto se mantiene completamente separado del entrenamiento. El cruce espectro-parámetros se realiza por identificador de estrella, y tanto la fusión de catálogos como el filtro FT26 se fijan *a priori*, antes de cualquier evaluación del modelo. De las 184 estrellas O válidas, 116 provienen sólo de Holgado et al. [7], 36 sólo de de Burgos et al. [4] y 32 son comunes a ambos catálogos; estas últimas se fusionan en una única entrada (sin duplicados), y los desacuerdos sistemáticos entre ambos *pipelines* se asumen como un piso de ruido en las etiquetas (§5).

Aumento de datos. Dado el tamaño limitado de la grilla sintética, aplicamos data augmentation físicamente motivada para simular efectos instrumentales y atmosféricos: desplazamiento Doppler aleatorio (± 5 px), ensanchamiento gaussiano ($\sigma \in [0, 2.5]$ px), *veiling* continuo ($f_v \in [0, 0.2]$), deformación polinomial del continuo, offset vertical (≤ 0.01), y ruido aditivo compuesto por una componente correlacionada de baja frecuencia más ruido blanco suavizado. Cada espectro se replica 4 veces con aumentaciones independientes, resultando en un conjunto de entrenamiento efectivo de $\sim 4 \times 0.8 \times N_{\text{syn}}$ muestras.

Mismatch rotacional sintético-observado. La grilla ISOSCELES contiene perfiles H α sintéticos generados *sin rotación estelar*, mientras que las observaciones de estrellas masivas presentan ensanchamiento rotacional con $v \sin i$ típicamente entre 50 y 300 km/s para estrellas O [7] y de Burgos [4]. Este mismatch es una fuente conocida de degradación: Ortiz et al. [9] lo manejan deconvolucionando los espectros observados antes de la clasificación. En nuestro pipeline adoptamos la estrategia opuesta: en lugar de deconvolucionar observaciones, incluimos en la augmentación sintética un ensanchamiento gaussiano con $\sigma \in [0, 2.5]$ px que actúa como un proxy del ensanchamiento rotacional sumado a efectos instrumentales. Reconocemos que el kernel gaussiano no captura la forma exacta del perfil de rotación, por lo que esta es una aproximación de primer orden. Una mejora natural, que dejamos como trabajo futuro,

es convolucionar con kernels rotacionales realistas usando $v \sin i$ muestreado de la distribución empírica de los catálogos IACOB.

3.3 Arquitectura de red neuronal

Empleamos una red neuronal convolucional residual 1D (ResNet-1D) como encoder espectral, motivada por los resultados de Cvrček et al. [3] quienes demostraron que arquitecturas ResNet superan consistentemente a CNNs puras en la reconstrucción de líneas de absorción en espectros de alta resolución (HARPS). En particular, Cvrček et al. reportan que deencoders ResNet alcanzan errores de reconstrucción 0.0064 ± 0.0011 frente a 0.0139 ± 0.0026 de CNNs estándar, atribuyendo esta ventaja a las conexiones residuales que mitigan la dilución de información en capas profundas [3, Sect. 4.2.1]. Una ablación arquitectónica directa sobre nuestro problema —un MLP o una CNN sin conexiones residuales como líneas de base— queda como trabajo futuro; aquí nos apoyamos en esta evidencia externa para justificar la elección de ResNet-1D.

La arquitectura consta de los siguientes componentes:

Codificador ResNet-1D. La entrada $\mathbf{x} \in \mathbb{R}^{200 \times 1}$ (espectro unicanal) se procesa mediante:

- (1) Una convolución inicial Conv1D(32, 7, stride = 2) seguida de BatchNorm y ReLU.
- (2) Tres bloques residuales 1D con progresión de canales (32 $\rightarrow$ 64 $\rightarrow$ 128); los dos últimos cambian la dimensión de canales y emplean un atajo de proyección 1×1 . Todos los bloques preservan la longitud espacial (stride = 1); la reducción espacial proviene de la convolución inicial (stride = 2) y del *Global Average Pooling*.
- (3) *Global Average Pooling* 1D para reducir a un vector de características.
- (4) Capa densa de *bottleneck* con latent_dim = 64 y activación ReLU.

Cada bloque residual implementa la identidad clásica de He et al. [6] adaptada a convoluciones unidimensionales:

$$\mathbf{h}_{l+1} = \sigma(\mathcal{F}(\mathbf{h}_l; \{W_l\}) + \mathbf{h}_l), \quad (3)$$

donde $\mathcal{F}$ representa dos convoluciones 1D de tamaño (*kernel*) 3 con BatchNorm intermedio, y σ es ReLU. Cuando las dimensiones espaciales o de canales difieren, la conexión *shortcut* se proyecta mediante convolución 1×1 con stride apropiado. La Figura 2 resume el encoder, las cuatro cabezas multitarea y el flujo de ambos términos de pérdida.

Cabezas de predicción multi-tarea. Desde la representación latente $\mathbf{z} \in \mathbb{R}^{64}$, cada parámetro se predice mediante una cabeza independiente con arquitectura Dense(128) $\rightarrow$ BN $\rightarrow$ Dropout(0.3) $\rightarrow$ Output. Los cuatro parámetros (T_{eff} , $\log g$, $\log \dot{M}$, R_*) se predicen mediante salida lineal (regresión continua en espacio normalizado [0, 1]). La grilla ISOSCELES discretiza $\log g$ en seis valores por construcción ($\mathcal{G} = \{3.15, 3.30, 3.45, 3.60, 3.75, 3.90\}$); las etiquetas sintéticas de validación y prueba viven exactamente sobre esos nodos. Por ello, al medir el rendimiento in-distribution sobre ISOSCELES proyectamos la predicción continua al nodo más cercano (*snap*):

$$\widehat{\log g}_{\text{snap}} = \arg \min_{g_c \in \mathcal{G}} \left| \widehat{\log g} - g_c \right|, \quad (4)$$




Figure 2: Arquitectura ResNet-1D con cabezas multitarea y términos de pérdida. Las flechas continuas (grises) indican el flujo de *forward pass*; las punteadas azules conectan las predicciones con $\mathcal{L}_{\text{sup}}$ (pérdida supervisada); las punteadas rojas indican el cálculo del residuo físico (Ec. 7) sobre las predicciones que alimenta $\mathcal{L}_{\text{phys}}$.

En la evaluación fuera de distribución sobre IACOB —cuyas estrellas reales poseen $\log g$ continuo— reportamos la predicción sin *snap*, evitando introducir cuantización artificial e inflar el error para estrellas situadas entre nodos. Crucialmente, el *snap* se aplica únicamente en la evaluación in-distribution; durante el entrenamiento, tanto $\mathcal{L}_{\text{sup}}$ como $\mathcal{L}_{\text{phys}}$ operan sobre el valor continuo $\widehat{\log g}$, preservando la diferenciabilidad end-to-end.

El número total de parámetros entrenables es $\approx 10^5$, lo que permite entrenamiento eficiente en hardware modesto.

3.4 Función de pérdida compuesta

La función de pérdida total combina un término de supervisión estándar con una restricción física derivada de la prescripción auto-consistente de Figueroa-Tapia et al. [5].

Pérdida supervisada. Todos los parámetros se predicen por regresión continua en espacio normalizado (Ec. 2), por lo que la pérdida supervisada es un MSE uniforme:

$$\mathcal{L}_{\text{sup}} = \frac{1}{4} \sum_{k \in \{T_{\text{eff}}, \log g, \log \dot{M}, R_*\}} (\tilde{y}_k - \hat{y}_k)^2. \quad (5)$$

Dado que $\mathcal{L}_{\text{sup}}$ opera enteramente en $[0, 1]$, las contribuciones de los cuatro parámetros están en escalas comparables por construcción, evitando que el optimizador se sesgue hacia parámetros con rangos numéricos mayores (e.g. $T_{\text{eff}} \sim 10^4$ vs. $\log g \sim 4$). En contraste, $\mathcal{L}_{\text{phys}}$ debe evaluarse en espacio físico: las predicciones normalizadas $\tilde{y}$ se desnormalizan antes de aplicar la prescripción CNO, garantizando que el residuo r_{phys} esté expresado en unidades físicas.

Pérdida física. Para el término de penalización empleamos los valores centrales de la prescripción CNO (Ec. 1):

$$\log \dot{M}_{\text{CNO}} = -20.74 + 1.44 \log \left(\frac{R_*}{R_{\odot}} \right) - 3.85 \log g + 16.81 \log \left(\frac{T_{\text{eff}}}{1000 \text{ K}} \right). \quad (6)$$

Las incertidumbres de los coeficientes (Ec. 1) no se propagan al término de pérdida en este trabajo: tratarlas requeriría un esquema bayesiano o una función de pérdida con varianza no constante que dejamos como trabajo futuro. Esta decisión implica que $\mathcal{L}_{\text{phys}}$ penaliza desviaciones respecto al valor central de la prescripción, asumiéndolo como verdad de referencia durante el entrenamiento.

Definimos el residuo físico para una predicción $\hat{y}$ como:

$$r_{\text{phys}}(\hat{y}) = \log \dot{M} - \log \dot{M}_{\text{CNO}}(\hat{T}_{\text{eff}}, \widehat{\log g}, \hat{R}_*), \quad (7)$$

y la pérdida física como:

$$\mathcal{L}_{\text{phys}} = \frac{1}{N} \sum_{i=1}^N \left(r_{\text{phys}}(\hat{y}_i) \right)^2. \quad (8)$$

Empleamos un MSE sobre el residuo r_{phys} por su diferenciabilidad suave y porque penaliza con fuerza las violaciones grandes —predicciones lejos de la variedad CNO, justo el régimen que buscamos corregir—; alternativas robustas (Huber, MAE o pérdidas por cuantiles sobre el residuo logarítmico), que atenúan la influencia de *outliers*, son una extensión natural que dejamos como trabajo futuro.

La Figura 3 esquematiza este cómputo: tres salidas de la red alimentan la prescripción CNO y el resultado se compara con $\log \dot{M}$.




Figure 3: Esquema de $\mathcal{L}_{\text{phys}}$ (Ec. 8). Tres salidas de la red ($\hat{T}_{\text{eff}}$, $\widehat{\log g}$, $\hat{R}_*$) se evalúan en la prescripción CNO (Ec. 6) y se comparan con $\log \dot{M}$ mediante MSE (Ec. 7). Flechas continuas: cómputo forward; punteadas: residuo. La restricción es diferenciable y no requiere etiquetas adicionales.

Pérdida total con activación diferida y rampa lineal. Para evitar que la restricción física domine prematuramente y “atasque” el entrenamiento en mínimos subóptimos, empleamos un scheduler bifásico para el peso λ_{phys} :

$$\lambda_{\text{phys}}(e) = \begin{cases} 0, & e < e_{\text{delay}}, \\ \lambda_{\text{max}} \cdot \min\left(1, \frac{e - e_{\text{delay}}}{e_{\text{ramp}}}\right), & e \geq e_{\text{delay}}, \end{cases} \quad (9)$$

donde e es la época actual, e_{delay} el número de épocas de pre-entrenamiento supervisado puro (fase de delay, $\lambda_{\text{phys}} = 0$), e_{ramp} la duración de la rampa de activación lineal hasta alcanzar el peso final λ_{max} . La distinción entre ambos parámetros es clave: e_{delay} controla cuándo comienza a actuar la restricción física, mientras que e_{ramp} controla con qué velocidad alcanza su peso objetivo.

La pérdida total es:

$$\mathcal{L}_{\text{total}} = \mathcal{L}_{\text{sup}} + \lambda_{\text{phys}}(e) \cdot \frac{\mathcal{L}_{\text{phys}}}{\mathcal{L}_{\text{phys}}^{\text{ref}}}, \quad (10)$$

donde $\mathcal{L}_{\text{phys}}^{\text{ref}}$ es el MSE físico de las etiquetas sintéticas respecto a la prescripción CNO (Ec. 6), computado una sola vez sobre el conjunto de entrenamiento antes de iniciar el optimizador y tratado como constante durante todo el proceso. Este factor normaliza la escala del término físico haciéndola comparable con $\mathcal{L}_{\text{sup}}$ independientemente del valor de λ_{max} .

Interpretación conceptual de λ_{phys} . Reconocemos una sutileza importante en la interpretación del peso λ_{phys} . Tanto las etiquetas de $\log \dot{M}$ en ISOSCELES como la prescripción CNO de FT26 son construcciones teóricas que pueden discrepar sistemáticamente entre sí. En consecuencia, λ_{phys} no representa un balance puro entre “datos observacionales” y “física”, sino entre dos prescripciones teóricas alternativas. Optamos por preferir FT26 como restricción suave por dos razones: (a) incorpora un tratamiento más reciente y autoconsistente de la dilución del flujo UV causada por líneas metálicas, corrigiendo la sobreestimación sistemática de $\dot{M}$ de prescripciones previas [5]; y (b) ha sido validada externamente con $R^2 = 0.929$ sobre datos de ajuste. Cuantificamos la discrepancia entre ambas prescripciones sobre el conjunto sintético mediante $\mathcal{L}_{\text{phys}}^{\text{ref}}$, cuyo valor sobre el conjunto de entrenamiento es $\mathcal{L}_{\text{phys}}^{\text{ref}} = 2.30$ (en dex² sobre $\log \dot{M}$); un valor alto de $\mathcal{L}_{\text{phys}}^{\text{ref}}$ indicaría que ambas teorías son inconsistentes sobre el dominio ISOSCELES y que un peso λ_{phys} grande sesgaría las predicciones hacia FT26 en detrimento del ajuste a las etiquetas sintéticas.

Balanceo entre términos de pérdida y alternativas adaptativas. La función de pérdida total combina dos términos que viven en espacios numéricos distintos: $\mathcal{L}_{\text{sup}}$ se evalúa en el espacio normalizado $[0, 1]$ (Ec. 2) sobre los cuatro parámetros, mientras que $\mathcal{L}_{\text{phys}}$ se evalúa en espacio físico, como un MSE sobre el residuo de $\log \dot{M}$ medido en dex (Ec. 7). Esta diferencia de unidades es la fuente de desbalance que motivó la observación de los revisores. Para documentarla, medimos las normas de los gradientes de cada término respecto a los parámetros del encoder compartido θ sobre un *batch* real de 2048 espectros (Tabla 2). En el instante en que la rampa activa la física —con la red supervisada ya convergida— $\|\nabla_{\theta} \mathcal{L}_{\text{phys}}\|$ supera a $\|\nabla_{\theta} \mathcal{L}_{\text{sup}}\|$ por un factor ~ 190 (más de dos órdenes de magnitud): sumar ambos términos sin tratamiento haría que el paso del optimizador estuviese dominado casi por completo por la física, suprimiendo el ajuste espectral. Es importante notar que la similitud coseno entre ambos gradientes es de sólo +0.11: los términos son casi ortogonales, no antagónicos. El conflicto es por tanto de *magnitud* y no de *dirección*, lo que implica que un único peso escalar λ_{phys} es suficiente para balancearlos, sin necesidad de cirugía de gradientes. Un desbalance secundario, de menor orden, proviene de la disparidad entre los coeficientes de la prescripción CNO (de 1.44 a 16.81), que produce gradientes de magnitud desigual respecto a $\hat{T}_{\text{eff}}$, $\log g$ y $\hat{R}_*$.

Frente a este desbalance adoptamos, en la configuración principal de λ_{phys} fijo, un conjunto de mitigaciones estáticas. Primero, la normalización Min-Max (Ec. 2) garantiza que los cuatro parámetros

Table 2: Normas de los gradientes de cada término de pérdida respecto al encoder compartido θ , sobre un *batch* de 2048 espectros sintéticos. El desbalance dominante es de *magnitud* ($\sim 190\times$ al activarse la física) y persiste tras la normalización por $\mathcal{L}_{\text{phys}}^{\text{ref}}$ ($\sim 83\times$); la similitud coseno cercana a cero confirma que los gradientes son casi ortogonales. La última fila muestra el peso w_{phys} que iguala ambas normas, que es el que GradNorm aprende de forma adaptativa (§4.7).

	$\ \nabla \mathcal{L}_{\text{sup}}\ $	$\ \nabla \mathcal{L}_{\text{phys}}\ $	razón	cos
Inicialización	0.20	19.9	98 $\times$	+0.52
Activación física	1.74	333	192 $\times$	+0.11
tras $\div \mathcal{L}_{\text{phys}}^{\text{ref}}$	1.74	145	83 $\times$	+0.11
con GradNorm ($w_{\text{phys}}=0.012$)	1.74	1.74	1.0 $\times$	+0.11

contribuyan a $\mathcal{L}_{\text{sup}}$ en escalas comparables, eliminando el sesgo trivial hacia parámetros con rangos numéricos mayores (e.g. $T_{\text{eff}} \sim 10^4$ frente a $\log g \sim 4$). Segundo, la división por $\mathcal{L}_{\text{phys}}^{\text{ref}}$ (Ec. 10) —un factor constante computado una sola vez sobre las etiquetas sintéticas— lleva el *valor* del término físico a una escala de referencia $\mathcal{O}(1)$ independiente de las unidades de $\log \dot{M}$, dando a λ_{phys} una interpretación directa como peso relativo. Conviene precisar que esta normalización reescala el *valor* de la pérdida, no la *norma* de su gradiente: como muestra la Tabla 2, reduce el desbalance de gradientes de $\sim 190\times$ a $\sim 83\times$, pero no lo elimina. El balance efectivo restante lo fijan tres mecanismos complementarios: (i) la activación diferida y la rampa lineal de λ_{phys} (Ec. 9), que introducen la física gradualmente sobre una red ya convergida; (ii) el recorte global de norma de gradiente ($\|g\| \leq 1$), que acota cada paso con independencia de la magnitud cruda del término físico; y (iii) el valor $\lambda_{\text{phys}} = 0.25$ seleccionado por búsqueda en grilla (§3.5). Con dicho valor, la contribución efectiva de la física al gradiente compartido sigue siendo $\sim 20\times$ la supervisada en el instante de activación; este dominio es deliberado —la restricción está pensada para reconfigurar el comportamiento fuera de distribución— y su costo, una degradación controlada del MAE in-distribution, se cuantifica en los resultados.

Como los gradientes son casi ortogonales (Tabla 2), no recurrimos a métodos de proyección de gradientes (tipo PCGrad), pensados para gradientes antagónicos: el conflicto es de magnitud, no de dirección. Ahora bien, ese desbalance residual de magnitud ($\sim 83\times$) implica que *ningún* λ_{phys} fijo iguala las normas de los gradientes de ambos términos. Para abordar este punto de forma directa —y responder a la observación de los revisores sobre el escalado de gradientes— implementamos además el balanceo adaptativo GradNorm [2], que reemplaza el escalar fijo por un peso w_{phys} actualizado en cada paso de modo que las normas de los gradientes de $\mathcal{L}_{\text{sup}}$ y $\mathcal{L}_{\text{phys}}$ respecto al encoder compartido se igualen, moduladas por la tasa de aprendizaje relativa de cada término (parámetro de asimetría $\alpha = 1.5$). A diferencia de λ_{phys} , GradNorm no introduce un peso que ajustar a mano: el balance se determina solo. Reportamos esta variante junto a las configuraciones de λ fijo en §4.7, donde mostramos que (a) conduce la razón de gradientes de $\sim 83\times$ a $\sim 1\times$ con un peso aprendido $w_{\text{phys}} \approx 0.01$, y (b) la corrección fuera de distribución *persiste*, lo que confirma que el efecto del término físico es robusto al

mecanismo de balanceo y no un artefacto de un λ ajustado manualmente. Mantenemos $\lambda_{\text{phys}} = 0.25$ como configuración principal por comparabilidad con el barrido de sensibilidad (§3.5), y reservamos la ponderación por incertidumbre como extensión para versiones con múltiples restricciones físicas.

La diferenciabilidad de $\mathcal{L}_{\text{phys}}$ respecto a todas las salidas predichas permite retropropagación directa mediante autodiferenciación, sin requerir información adicional del dominio observacional.

3.5 Estrategias de entrenamiento

Evaluamos dos configuraciones principales que permiten aislar el efecto de la restricción física:

Baseline Entrenamiento supervisado puro con $\lambda_{\text{phys}} \equiv 0$. Sirve como referencia para cuantificar la degradación por brecha sintética.

PGNN (Physics-Guided Neural Network) Entrenamiento con la función de pérdida compuesta de la Ec. (10), incluyendo el término físico con rampa lineal de λ_{phys} . Se evalúan tres variantes de ablación:

- (1) *ft (fine-tuning)* sobre el Baseline ya entrenado: $e_{\text{delay}} = 0$, $e_{\text{ramp}} = 10$. Al partir de pesos supervisados ya convergidos, la fase de delay es innecesaria y la rampa actúa desde la primera época.
- (2) *scratch (from scratch)* en dos fases: $e_{\text{delay}} = 10$, $e_{\text{ramp}} = 20$. El delay garantiza que el encoder aprenda primero representaciones espectrales estables antes de que la restricción física comience a actuar.
- (3) *domain*: idéntico scheduler a *scratch*, con penalizaciones de dominio adicionales (peso $w_{\text{dom}} = 0.1$) que castigan predicciones físicamente inadmisibles, $R_* < 0$ (radio negativo) y $\log \dot{M} > 0$, imponiendo el dominio físico directamente en la pérdida.

Como segundo eje de ablación, cada estrategia se entrena en dos modos según la *fuerza* de la restricción física: *synth-only*, con $\mathcal{L}_{\text{phys}}$ evaluada únicamente sobre espectros sintéticos; y *+obs*, que tras completarse la rampa añade un término $w_{\text{obs}} \mathcal{L}_{\text{phys}}$ evaluado sobre los espectros observados (IACOB, 184; UVES POP O, 12) *sin usar sus etiquetas*. Fijamos $w_{\text{obs}} = 0.01$, un orden de magnitud por debajo de λ_{phys} : como el término se activa tras la rampa —con la red ya convergida y satisfaciendo aproximadamente la prescripción CNO sobre el dominio observado— su contribución resultante es $\sim 8\%$ de $\mathcal{L}_{\text{sup}}$. El valor conservador es deliberado: al carecer este término de supervisión, un peso elevado arriesgaría colapsar las predicciones hacia la variedad CNO en detrimento del ajuste espectral. El modo *+obs* permite que la red ajuste su consistencia física directamente en el dominio observacional mediante la única restricción no supervisada disponible: la prescripción CNO. El cruce de ambos ejes produce 6 configuraciones PGNN (3 estrategias $\times$ {synth-only, +obs}) que, junto al Baseline, conforman las 7 configuraciones reportadas. En conjunto, las ablaciones aíslan el efecto de: (a) el término físico, (b) la estrategia de activación (diferida vs. fine-tuning), (c) las penalizaciones de dominio, y (d) la inclusión de física observacional.

Todos los modelos se entrenan con optimizador Adam ($\beta_1 = 0.9$, $\beta_2 = 0.999$), *learning rate* inicial 5×10^{-4} , con reducción por plato ($\times 0.5$, paciencia 4–5) y *early stopping* (paciencia 8–10, restauración




Figure 4: Dinámica de entrenamiento de PGNN-*scratch* ($\lambda_{\text{phys}} = 0.25$). Arriba: pérdidas supervisada ($\mathcal{L}_{\text{sup}}$) y física ($\mathcal{L}_{\text{phys}}$), entrenamiento y validación, por época. Abajo: el peso $\lambda_{\text{phys}}(e)$ con su fase de *delay* ($e < e_{\text{delay}} = 10$) y rampa lineal (Ec. 9). Al activarse la física, $\mathcal{L}_{\text{phys}}$ cae dos órdenes de magnitud sin degradar $\mathcal{L}_{\text{sup}}$: la restricción no desestabiliza el ajuste espectral.

de mejores pesos). El tamaño de *batch* es 2048 y se entrena hasta un máximo de 200 épocas. Se aplica recorte de norma de gradiente máxima 1.0 y precisión mixta (con $\mathcal{L}_{\text{phys}}$ evaluada en `float32`). En las variantes PGNN, el *checkpoint* final se fuerza al completarse la rampa (*reset-after-ramp*), de modo que el modelo evaluado siempre incorpora la física y no el mínimo puramente supervisado que el *early stopping* restauraría. El *learning rate* se mantiene idéntico en todas las variantes para garantizar que las diferencias observadas se deban exclusivamente a la estrategia de activación, la fuente de la física o las penalizaciones de dominio.

Selección de λ_{phys} . El peso λ_{phys} se elige mediante un barrido $\lambda_{\text{phys}} \in \{0.05, 0.10, 0.20, 0.25, 0.30, 0.50\}$ aplicado a cada estrategia con el scheduler y el resto de hiperparámetros fijos. Fijamos $\lambda_{\text{phys}} = 0.25$ *a priori*, como un valor moderado: su elección *no* se optimiza sobre los conjuntos observacionales. El barrido sobre IACOB (Tabla 7) es un análisis de sensibilidad *a posteriori* —que muestra que el error OOD es plano frente a λ_{phys} — y no un criterio de selección, evitando el ajuste de hiperparámetros sobre datos de evaluación. El costo in-distribution, medible sobre la validación sintética, crece monótonamente con λ_{phys} , lo que respalda mantener un valor moderado. Los parámetros del scheduler (e_{delay} , e_{ramp}) se determinaron a partir de curvas de convergencia preliminares sobre el conjunto de validación, asegurando que la restricción física se active solo una vez que $\mathcal{L}_{\text{sup}}$ se ha estabilizado. Para garantizar reproducibilidad estadística, los experimentos principales se ejecutan con cinco semillas aleatorias independientes ({42, 123, 2026, 7, 2024}); el barrido de sensibilidad de λ_{phys} (Tabla 7) se reporta con las tres primeras. La Figura 4 ilustra la dinámica de entrenamiento bifásica resultante.

3.6 Protocolo de validación y métricas

Partición de datos. El conjunto sintético ISOSCELES (subconjunto O, 33 444 espectros) se divide en 80% entrenamiento, 10% validación y 10% prueba mediante partición aleatoria. Los conjuntos observacionales (UVES POP e IACOB, descritos en §3.2) se reservan para evaluación *out-of-distribution* (OOD): sus *etiquetas* nunca intervinen en el entrenamiento ni en la selección de hiperparámetros. La configuración principal (*synth-only*) no observa ningún espectro real, por lo que su evaluación OOD es estrictamente inductiva; las variantes *+obs* (§3.5) usan los espectros observados *sin etiqueta* en la restricción física —un uso transductivo de las entradas que tenemos en cuenta al interpretar sus métricas.

Métricas. Organizamos las métricas en tres niveles de evaluación, de menor a mayor exigencia:

- (1) **Rendimiento in-distribution** (prueba sintética): MAE y RMSE por parámetro. Establece el techo de rendimiento del modelo en ausencia de brecha de dominio.
- (2) **Coherencia distribucional OOD** (UVES POP): distancia de Wasserstein-1 (W_1) entre la distribución *real* de parámetros del conjunto sintético de prueba (etiquetas ISOSCELES) y la distribución *predicha* sobre UVES POP. Tomamos como referencia las etiquetas sintéticas reales —y no las predicciones del modelo sobre el conjunto sintético— para que la métrica no pueda minimizarse trivialmente colapsando ambas distribuciones predichas a una misma banda. W_1 cuantifica el desplazamiento promedio entre distribuciones en unidades del parámetro, capturando la magnitud de la discrepancia y no solo su significancia estadística
- (3) **Error OOD contra etiquetas reales** (IACOB): MAE, RMSE y sesgo ($\bar{\delta} = \overline{\hat{y} - y}$) por parámetro contra los valores de literatura. T_{eff} y $\log g$ se evalúan contra ambos catálogos; R_* se evalúa únicamente contra Holgado et al. [7], que proporciona estimaciones directas.

Adicionalmente reportamos dos métricas transversales:

- **Consistencia física:** $\mathcal{L}_{\text{phys}}$ (Ec. 8) promediada por separado en el conjunto sintético de prueba y en cada conjunto observacional. Dado que la prescripción CNO es el mismo término utilizado durante el entrenamiento del modelo PGNN, esta métrica cuantifica la coherencia interna de las predicciones y no constituye una validación independiente de $\log \dot{M}$; y no la interpretamos como tal.
- **Brecha de dominio:** $\Delta_k = \text{MAE}_k^{\text{IACOB}} - \text{MAE}_k^{\text{synth}}$ por parámetro k . Una brecha positiva indica degradación al pasar de datos sintéticos a observados; la hipótesis central predice que PGNN reducirá Δ_k respecto al Baseline.
- **Tasa de predicciones fuera de rango físico:** porcentaje de predicciones sobre IACOB que caen fuera de los rangos de validez FT26 para estrellas O ($T_{\text{eff}} \in [30\,000, 50\,000]$ K, $\log g \in [2.9, 4.3]$, $R_* \in [7, 70] R_\odot$), reportado por parámetro. A diferencia de $\mathcal{L}_{\text{phys}}$, no depende de la prescripción CNO ni de etiquetas: sólo verifica si las predicciones respetan los límites físicos del régimen O, por lo que constituye una comprobación de admisibilidad independiente.

Baselines. El **Baseline** ($\lambda_{\text{phys}} \equiv 0$) cuantifica la degradación causada por la brecha sintética sin mitigación. La variante PGNN *from-scratch* (ii) sirve como control adicional: durante su fase de delay ($e < e_{\text{delay}}$, donde $\lambda_{\text{phys}} = 0$), es funcionalmente idéntica al Baseline pero con el mismo scheduler de *learning rate*. Comparar ambos verifica que la arquitectura de entrenamiento bifásico no introduce ventajas artificiales, aislando el efecto neto del término físico.

4 Resultados

Reportamos las siete configuraciones descritas en §3.5: el **Baseline** supervisado y las seis variantes PGNN que cruzan la estrategia de activación (*ft*, *scratch*, *domain*) con la fuente de la restricción física (*synth-only*, *+obs*), todas con $\lambda_{\text{phys}} = 0.25$. Cada celda es la media $\pm$ desviación estándar sobre las cinco semillas {42, 123, 2026, 7, 2024}. La evaluación sigue el protocolo de tres niveles de §3.6; recordamos que $\log g$ se proyecta a la grilla (*snap*) sólo en la evaluación in-distribution sobre ISOSCELES, no en IACOB.

4.1 Rendimiento in-distribution (ISOSCELES)

La Tabla 3 establece el techo de rendimiento en ausencia de brecha de dominio. El Baseline alcanza el menor error en los cuatro parámetros (T_{eff} : 657 K; $\log g$: 0.013; $\log \dot{M}$: 0.24; R_* : 0.59 $R_\odot$). Todas las variantes PGNN degradan el ajuste sintético: el MAE de T_{eff} se duplica (~ 1300 –1540 K), el de $\log g$ se sextuplica (~ 0.07 –0.09) y el de $\log \dot{M}$ se triplica (~ 0.74 –0.78). Esta degradación es esperada y deliberada: la restricción física reconfigura el modelo para priorizar la consistencia fuera de distribución a costa del ajuste in-distribution. La magnitud del costo es estable entre estrategias, lo que indica que proviene del término físico en sí y no de la estrategia de activación.

Table 3: Nivel 1 — MAE in-distribution sobre la prueba sintética ISOSCELES (menor es mejor). T_{eff} en K, R_* en $R_\odot$, $\log g$ y $\log \dot{M}$ adimensionales.

Config.	T_{eff}	$\log g$	$\log \dot{M}$	R_*
Baseline	660 $\pm$ 250	0.013 $\pm$ 0.011	0.232 $\pm$ 0.055	0.51 $\pm$ 0.26
<i>ft</i>	1371 $\pm$ 47	0.074 $\pm$ 0.003	0.755 $\pm$ 0.014	0.85 $\pm$ 0.05
<i>scratch</i>	1526 $\pm$ 37	0.080 $\pm$ 0.004	0.750 $\pm$ 0.008	0.92 $\pm$ 0.04
<i>domain</i>	1511 $\pm$ 70	0.079 $\pm$ 0.003	0.744 $\pm$ 0.009	0.92 $\pm$ 0.01
<i>ft+obs</i>	1474 $\pm$ 231	0.080 $\pm$ 0.013	0.780 $\pm$ 0.017	1.02 $\pm$ 0.10
<i>scratch+obs</i>	1353 $\pm$ 45	0.087 $\pm$ 0.003	0.754 $\pm$ 0.009	0.97 $\pm$ 0.05
<i>domain+obs</i>	1283 $\pm$ 84	0.087 $\pm$ 0.002	0.750 $\pm$ 0.023	0.99 $\pm$ 0.04

4.2 Error fuera de distribución contra literatura (IACOB)

La Tabla 4 es el resultado central. Sobre las 184 estrellas IACOB reales, el Baseline exhibe un error catastrófico y de alta varianza: $\text{MAE}(T_{\text{eff}}) = 10\,343$ K con un sesgo de +10 091 K —el modelo *sobreesestima* sistemáticamente la temperatura en ~ 10 kK—, $\text{MAE}(\log g) = 0.40$ con sesgo +0.27, y $\text{MAE}(R_*) = 4.6 R_\odot$ con sesgo $-3.8 R_\odot$ (subestima el radio).

Todas las variantes PGNN colapsan este error a una banda estrecha y casi independiente de la semilla: $\text{MAE}(T_{\text{eff}}) \approx 3460$ –3730 K (reducción del $\sim 66\%$), $\text{MAE}(\log g) \approx 0.25$ –0.26 ($\sim 37\%$) y $\text{MAE}(R_*) \approx 3.5$ –3.6 $R_\odot$ ($\sim 25\%$). Más relevante que el MAE es la *corrección del sesgo*: el sesgo de T_{eff} cae de +10 kK a ~ -2.3 kK, el de $\log g$ de +0.27

a ~ -0.10 y el de R_* de -3.8 a ~ 0 . La restricción física no sólo reduce la dispersión sino que reubica las predicciones dentro del régimen físico, confirmando la hipótesis central para T_{eff} , $\log g$ y R_* . La mejor configuración en T_{eff} es *ft* (3460 K); las diferencias entre estrategias de activación y entre *synth-only* y *+obs* son de segundo orden frente al salto respecto al Baseline. La Figura 5 visualiza esta corrección: las predicciones del Baseline (rojo) se alejan de la recta 1:1 $-T_{\text{eff}}$ y $\log g$ sobreestimados, R_* subestimado— mientras que PGNN (azul) las recentra sobre la diagonal y dentro del rango físico (banda verde).

Table 4: Nivel 3 — Error fuera de distribución sobre IACOB contra etiquetas de literatura. MAE (menor es mejor) y sesgo $\bar{\delta} = \hat{y} - y$ (más cercano a 0 es mejor). T_{eff} y $\log g$ sobre 184 estrellas; R_* sobre las 148 con radio disponible.

Config.	T_{eff} [K]		$\log g$		R_* [$R_\odot$]	
	MAE	sesgo	MAE	sesgo	MAE	sesgo
Baseline	10343 $\pm$ 2748	+10091	0.40 $\pm$ 0.09	+0.27	4.63 $\pm$ 0.15	-3.77
<i>ft</i>	3460$\pm$85	-2318	0.25	-0.09	3.46	-0.07
<i>scratch</i>	3732 $\pm$ 159	-2614	0.26	-0.11	3.56	+0.48
<i>domain</i>	3584 $\pm$ 179	-2452	0.26	-0.10	3.50	+0.17
<i>ft+obs</i>	3631 $\pm$ 164	-2651	0.26	-0.11	3.56	+0.43
<i>scratch+obs</i>	3635 $\pm$ 103	-2308	0.25	-0.10	3.58	+0.42
<i>domain+obs</i>	3550 $\pm$ 156	-2407	0.26	-0.11	3.61	+0.36

4.3 Coherencia distribucional (UVES POP)

La Tabla 5 reporta la distancia de Wasserstein-1 entre la distribución real de parámetros de la prueba sintética (etiquetas ISOSCELES) y la predicha sobre las 12 estrellas O de UVES POP (sin etiquetas). El patrón refuerza el de IACOB para T_{eff} : W_1 cae de ~ 7900 K (Baseline) a ~ 2100 – 2500 K en todas las variantes PGNN. Para $\log g$ la mejora es consistente aunque menor ($0.31 \rightarrow 0.12$ – 0.17). En cambio, $\log \dot{M}$ empeora ($0.67 \rightarrow 0.91$ – 1.01) y R_* muestra resultados mixtos (mejor con *domain*, $3.04 \rightarrow 2.02$; peor con *scratch*, $3.04 \rightarrow 3.39$). Discutimos estos dos casos de fallo en §5. La Figura 6 muestra las distribuciones predichas completas frente a la referencia sintética.

Table 5: Nivel 2 — Distancia de Wasserstein-1 entre la distribución real de parámetros de la prueba sintética (etiquetas ISOSCELES) y la predicha sobre UVES POP O (sin etiquetas; menor es mejor). Unidades del parámetro.

Config.	T_{eff}	$\log g$	$\log \dot{M}$	R_*
Baseline	7928 $\pm$ 2020	0.312	0.671	3.044
<i>ft</i>	2122$\pm$130	0.168	0.950	2.967
<i>scratch</i>	2430 $\pm$ 428	0.173	0.955	3.390
<i>domain</i>	2382 $\pm$ 420	0.121	0.912	2.020
<i>ft+obs</i>	2404 $\pm$ 436	0.173	0.957	3.042
<i>scratch+obs</i>	2493 $\pm$ 915	0.159	0.982	3.156
<i>domain+obs</i>	2413 $\pm$ 461	0.167	1.011	2.938

4.4 Admisibilidad física: tasa de predicciones fuera de rango

La Tabla 6 cuantifica qué fracción de las predicciones IACOB cae fuera de los rangos de validez FT26 —una comprobación que no usa la prescripción CNO ni etiquetas, sólo límites físicos del régimen O. El Baseline emite predicciones inadmisibles en el 18.6% de las

estrellas para T_{eff} , 5.7% para $\log g$ y 16.6% para R_* . La restricción física *elimina por completo* las violaciones de $\log g$ y R_* ($\approx 0\%$ en todas las variantes) y reduce drásticamente las de T_{eff} (hasta 3.8% con *ft*). Esto responde directamente a la motivación del trabajo (§3): el modelo deja de producir parámetros físicamente implausibles sobre datos reales (Figura 7).

Table 6: Tasa de predicciones fuera de rango físico sobre IACOB (porcentaje de estrellas fuera de los rangos de validez FT26; menor es mejor).

Config.	T_{eff} %	$\log g$ %	R_* %
Baseline	18.6 $\pm$ 15.1	5.7 $\pm$ 6.0	16.6 $\pm$ 9.4
<i>ft</i>	3.8$\pm$2.2	0.0	0.0
<i>scratch</i>	10.5 $\pm$ 7.5	0.0	0.1
<i>domain</i>	7.8 $\pm$ 5.9	0.0	0.0
<i>ft+obs</i>	10.3 $\pm$ 7.2	0.0	0.0
<i>scratch+obs</i>	7.7 $\pm$ 3.6	0.0	0.0
<i>domain+obs</i>	6.0 $\pm$ 2.3	0.0	0.0

4.5 Consistencia física y brecha de dominio

La pérdida física media $\mathcal{L}_{\text{phys}}$ cae de 2.08 (Baseline, prueba sintética) a ~ 0.01 en todas las variantes PGNN, y de forma análoga sobre UVES POP ($1.40 \rightarrow 0.02$ – 0.06) e IACOB ($0.59 \rightarrow 0.01$). Subrayamos que $\mathcal{L}_{\text{phys}}$ es el mismo término optimizado en entrenamiento, por lo que mide coherencia interna y *no* constituye una validación independiente de $\hat{M}$. La *brecha de dominio* $\Delta_k = \text{MAE}_k^{\text{IACOB}} - \text{MAE}_k^{\text{synth}}$ se reduce en todos los parámetros: para *ft*, $\Delta_{T_{\text{eff}}}$ pasa de 9683 a 2089 K, $\Delta_{\log g}$ de 0.39 a 0.18 y Δ_{R_*} de 4.12 a 2.60 $R_\odot$. La hipótesis $\Delta_k^{\text{PGNN}} < \Delta_k^{\text{Baseline}}$ se cumple en los tres parámetros con etiqueta real.

4.6 Sensibilidad a λ_{phys}

La Tabla 7 barre $\lambda_{\text{phys}} \in \{0.05, \dots, 0.50\}$ y reporta la MAE normalizada media sobre los tres parámetros con etiqueta IACOB (T_{eff} , $\log g$, R_* ; espacio $[0, 1]$), evitando privilegiar un solo parámetro. La ganancia OOD es *robusta* al peso: para cualquier λ y estrategia el error se mantiene en ~ 0.27 – 0.29 , dentro de la dispersión entre semillas —el spread por parámetro es $< 4\%$ en T_{eff} , $\log g$ y R_* por separado. No existe un óptimo agudo; recordamos que $\lambda_{\text{phys}} = 0.25$ se fija *a priori* (§3.5), no por este barrido. Esta robustez es deseable: el método no depende de un ajuste fino del hiperparámetro físico. La Figura 8 resume el compromiso in-distribution vs. OOD en la misma métrica.

4.7 Balanceo adaptativo de gradientes (GradNorm)

El desbalance residual de $\sim 83\times$ (Tabla 2) implica que ningún λ_{phys} fija iguala las normas de los gradientes de $\mathcal{L}_{\text{sup}}$ y $\mathcal{L}_{\text{phys}}$. Para resolverlo de forma directa entrenamos las tres estrategias con GradNorm (§3.4), que reemplaza el escalar fijo por un peso w_{phys} ajustado en cada paso para equilibrar dichas normas. El método converge a $w_{\text{phys}} \approx 0.01$ en las tres estrategias (0.0094, 0.0109, 0.0124 para *ft*, *scratch* y *domain*), *un orden de magnitud por debajo* de $\lambda_{\text{phys}} = 0.25$, llevando la razón de gradientes ponderada de $\sim 83\times$




Figure 5: Predicción vs. literatura sobre IACOB (semilla 42) para T_{eff} , $\log g$ y R_* . Baseline (rojo) frente a PGNN-ft (azul); línea discontinua = identidad 1:1. La banda verde marca la región físicamente admisible (rango de validez FT26 del parámetro: $\log g \in [2.9, 4.3]$, $R_* \in [7, 70] R_\odot$). El Baseline sobreestima T_{eff} y $\log g$ y subestima R_* ; la restricción física recentra las predicciones sobre la diagonal y dentro del régimen físico.




Figure 6: Distribuciones de parámetros predichas sobre las 12 estrellas O de UVES POP (color) frente a la distribución real de las etiquetas ISOSCELES (gris), referencia de la distancia W_1 (Tabla 5). Filas: Baseline y PGNN-ft (representativa; *scratch* y *domain* son casi idénticas; $\lambda_{\text{phys}} = 0.25$). La banda verde marca el rango válido del grido O. El Baseline desplaza T_{eff} y $\log g$ fuera del soporte real; PGNN concentra las predicciones dentro de él. Para $\log \dot{M}$ la determinación CNO colapsa la predicción a una banda estrecha (caso de fallo, §5).

Table 7: Sensibilidad a λ_{phys} : MAE normalizada media sobre $\{T_{\text{eff}}, \log g, R_*\}$ en IACOB (espacio $[0, 1]$, media 3 semillas). $\lambda_{\text{phys}} = 0.25^*$ se fija *a priori* (§3.5), no por ser el mínimo; la columna *rango* (máx–mín) muestra que el error OOD varía < 0.02 entre todos los pesos: el método es insensible a λ_{phys} .

Config.	0.05	0.10	0.20	0.25*	0.30	0.50	rango
<i>ft</i>	0.278	0.274	0.277	0.275	0.279	0.281	0.007
<i>scratch</i>	0.284	0.286	0.287	0.289	0.287	0.290	0.006
<i>domain</i>	0.277	0.276	0.280	0.280	0.279	0.280	0.004
<i>ft+obs</i>	0.286	0.286	0.281	0.282	0.279	0.277	0.009
<i>scratch+obs</i>	0.287	0.283	0.285	0.283	0.283	0.284	0.004
<i>domain+obs</i>	0.288	0.282	0.278	0.280	0.279	0.276	0.012

hacia el equilibrio: $\sim 1\times$ en el instante de activación (Tabla 2) y $\sim 0.3\times$ en promedio al converger, donde $\mathcal{L}_{\text{phys}}$ ya es pequeña y su gradiente disminuye.




Figure 7: Tasa de predicciones fuera del rango de validez FT26 sobre IACOB (media $\pm$ desv. est., 5 semillas). La restricción física elimina las violaciones de $\log g$ y R_* y reduce las de T_{eff} .

La Tabla 8 arroja dos conclusiones. Primera, *la corrección fuera de distribución persiste*: el MAE de T_{eff} sobre IACOB permanece en $\sim 3500\text{--}3700\text{ K}$ (e indistinguible del λ fijo dentro de la dispersión entre semillas; *scratch* incluso mejora, $3732 \rightarrow 3477$), y $\log g$ y R_* se mantienen. Esto descarta que la ganancia OOD provenga de un valor afortunado de λ : es *robusta al mecanismo de balanceo*. Segunda, GradNorm *reduce a la mitad el costo in-distribution*: al equilibrar las normas en lugar de imponer una dominancia fija, el MAE de T_{eff} sobre la prueba sintética cae de ~ 1470 a $\sim 670\text{ K}$ —prácticamente el del Baseline (660)— y el de $\log g$ de ~ 0.078 a ~ 0.040 . En otras palabras, $\lambda_{\text{phys}} = 0.25$ *sobre-pondera* la física: la restricción no necesita dominar el gradiente para reconfigurar el comportamiento OOD, basta con equilibrarlo. La contrapartida es que GradNorm no corrige las limitaciones estructurales de W_1 (el W_1 de $\log \dot{M}$ permanece alto, ~ 0.90 para *ft*, por la misma determinación CNO discutida en §5).




Figure 8: Compromiso in-distribution vs. OOD para PGNN-ft, en MAE normalizada media sobre T_{eff} , $\log g$ y R_* (espacio $[0, 1]$). El Baseline (estrella) tiene bajo error in-distribution pero OOD catastrófico; PGNN reduce el error OOD a la mitad con un costo in-distribution modesto. El tamaño del círculo es $\propto \lambda_{\text{phys}}$: el error OOD permanece plano a lo largo del barrido, confirmando la robustez al peso físico (Tabla 7). GradNorm (triángulo, §4.7) alcanza el mismo error OOD con un costo in-distribution $\sim 33\%$ menor que el mejor λ_{phys} fijo, dominando al barrido en sentido de Pareto.

Table 8: λ fijo ($= 0.25$) frente a GradNorm (peso w_{phys} adaptativo), media sobre 5 semillas. GradNorm reproduce la corrección OOD (MAE IACOB) reduciendo a la mitad el costo in-distribution (MAE ISOSCELES).

Estrat.	peso	in-dist (ISOSCELES)		OOD (IACOB)			
		T_{eff}	$\log g$	T_{eff}	$\log g$	R_*	w_{phys}
Baseline	—	660	0.013	10343	0.40	4.63	—
<i>ft</i>	$\lambda=0.25$	1371	0.074	3460	0.25	3.46	—
<i>ft</i>	GradNorm	657	0.038	3603	0.26	3.57	0.009
<i>scratch</i>	$\lambda=0.25$	1526	0.080	3732	0.26	3.56	—
<i>scratch</i>	GradNorm	696	0.043	3477	0.25	3.51	0.011
<i>domain</i>	$\lambda=0.25$	1511	0.079	3584	0.26	3.50	—
<i>domain</i>	GradNorm	660	0.041	3511	0.26	3.59	0.012

5 Discusión

5.1 Veredicto sobre la hipótesis

Los resultados sustentan la hipótesis para los tres parámetros con etiqueta de literatura (T_{eff} , $\log g$, R_*). La evidencia es convergente y de cuatro tipos. Primero, el MAE fuera de distribución cae 66%, 37% y 25% respectivamente (Tabla 4). Segundo, y más importante, se *corrige el sesgo*: el error del Baseline era casi enteramente sistemático —para T_{eff} , el sesgo $+10\,091$ K coincide casi con el MAE de $10\,343$ K— y la restricción física lo reduce a una fracción (-2318 K para *ft*), recentrando además $\log g$ ($+0.27 \rightarrow -0.09$) y R_* ($-3.77 \rightarrow -0.07$). Tercero, la admisibilidad física mejora: las violaciones de rango de $\log g$ y R_* se eliminan por completo y las de T_{eff} caen de 18.6% a

3.8% (Tabla 6). Cuarto, la *brecha de dominio* Δ_k —la cantidad que la hipótesis nombra explícitamente— se reduce en los tres parámetros (para *ft*: ΔT_{eff} de 9683 a 2089 K).

Conviene precisar el sentido de esta confirmación. La evidencia sustenta la hipótesis en su dimensión *agregada*: admisibilidad física (Tabla 6), corrección del sesgo sistemático y reducción de la brecha de dominio Δ_k (Tabla 4). No constituye, en cambio, una afirmación sobre la exactitud por estrella *individual*, que no medimos de forma directa: el efecto dominante de la restricción es relocalizar las predicciones dentro del régimen físico admisible y corregir el sesgo poblacional, no necesariamente ordenarlas estrella a estrella.

El mecanismo es coherente con la literatura de aprendizaje con restricciones físicas: la prescripción CNO acopla las cuatro cabezas mediante una relación algebraica válida sólo dentro del régimen O admisible, y minimizar $\mathcal{L}_{\text{phys}}$ proyecta las predicciones hacia esa variedad, de modo análogo a como Masclans et al. [8] y Ballester et al. [1] restringen sus soluciones, aunque aquí sobre un problema *inverso* de parámetros superficiales. Es decisivo que esto ocurra *sin ninguna etiqueta observada*: la restricción es la única señal fuera de distribución disponible, lo que confirma que la regularización de dominio basada en física opera en este régimen de cambio severo —donde la adaptación de dominio tipo Cycle-StarNet [10] requeriría grandes conjuntos observados no etiquetados y no garantizaría admisibilidad física. La hipótesis *no* queda validada, en cambio, para $\dot{M}$, por las razones que se detallan más adelante (§5, casos de fallo).

La consistencia física acerca los espectros observados a la variedad *sintética*. La Figura 9 proyecta (t-SNE) el latente de 64 dimensiones del encoder para espectros sintéticos y observados. Bajo el Baseline, los espectros observados quedan *aislados* en una región marginal del espacio latente, reflejando la brecha sintético-observado en la representación interna. Al introducir la restricción de consistencia física en la pérdida, el PGNN atrae los espectros observados hacia la variedad sintética: las nubes de IACOB y UVES POP O se relocalizan adyacentes a los espectros sintéticos, indicando que el encoder organiza ambos dominios en una geometría latente más coherente.

5.2 Análisis de componentes

El término físico domina, no la estrategia de activación. Tanto el costo in-distribution (Tabla 3) como la ganancia OOD (Tabla 4) son estables a través de *ft*, *scratch* y *domain*, lo que localiza el efecto en el término físico mismo. El control con *scratch* (activación diferida, sin *warm-start*) es informativo: un modelo que nunca visitó un óptimo puramente supervisado converge a la misma banda OOD que *ft* (que parte del Baseline ya convergido), descartando que la ganancia sea un artefacto del punto de partida supervisado.

ft es la mejor opción y la más barata. Alcanza el menor MAE(T_{eff}) (3460 K) y reutiliza el Baseline convergido sin fase de *delay*; lo adoptamos como configuración recomendada. Las penalizaciones explícitas de *domain* ($R_* < 0$, $\log \dot{M} > 0$) apenas mueven las métricas OOD sobre *scratch* —la restricción suave ya mantiene las predicciones admisibles— aunque estabilizan R_* (ver fallos).

La física observacional (+obs) es un resultado negativo informativo. Añadir $\mathcal{L}_{\text{phys}}$ sobre espectros observados sin etiqueta deja prácticamente inalteradas todas las métricas OOD (3460 para *ft* vs.




Figure 9: Embedding t-SNE del latente de 64 dimensiones del encoder (semilla 42): espectros sintéticos (gris) frente a observados (IACOB azul, UVES POP O rojo), bajo el Baseline y PGNN. El Baseline mantiene los observados aislados del soporte sintético; al incorporar la restricción de consistencia física, el PGNN los atrae hacia la variedad sintética, reduciendo la brecha de dominio en el espacio de representación. Cada panel es un espacio latente distinto (sólo la topología es comparable entre paneles).

3631 para $ft+obs$; $\log g = 0.26$ en todas las variantes). La causa es estructural: la prescripción CNO es una relación algebraica entre las cuatro *salidas*, independiente del espectro de entrada. Evaluada sobre entradas observadas no aporta ninguna dirección de gradiente que el término sintético no provea ya —la superficie de restricción es la misma con independencia del dominio. Por este canal, los espectros observados no etiquetados no añaden información. Es un negativo valioso: una restricción física *sobre las salidas* no puede, por sí sola, explotar datos del dominio objetivo como sí lo haría la adaptación de dominio en el espacio de *entrada*.

El balanceo de gradientes confirma robustez, no dependencia de λ . La variante GradNorm (§4.7) ofrece la prueba más fuerte de que la corrección OOD no es un artefacto del valor escogido de λ_{phys} . Al aprender el peso que iguala las normas de los gradientes, converge a $w_{phys} \approx 0.01$ —25× menor que $\lambda_{phys} = 0.25$ — y aun así reproduce la banda OOD de T_{eff} (~ 3500 K; *scratch* incluso mejora, $3732 \rightarrow 3477$). El efecto del término físico es, por tanto, robusto al mecanismo de ponderación. Más aún, al equilibrar las normas en lugar de imponer una dominancia fija, GradNorm *recupera* la mitad del costo in-distribution ($MAE(T_{eff})$ sintético $1371 \rightarrow 657$, prácticamente el del Baseline): la restricción no necesita dominar el gradiente para reconfigurar el comportamiento OOD, basta con equilibrarlo. Esto revela que $\lambda_{phys} = 0.25$ sobre-pondera la física, e identifica el balanceo adaptativo como la vía natural para extender este trabajo.

5.3 Casos de fallo

W_1 de $\log \dot{M}$ empeora ($0.67 \rightarrow 0.91$ – 1.01). Es esperado y estructural. La prescripción CNO *determina* $\log \dot{M}$ a partir de $\{T_{eff}, \log g, R_*$; el modelo no posee supervisión independiente de $\log \dot{M}$ más allá

de ISOSCELES, y FT26 ($R^2 = 0.929$) discrepa sistemáticamente de las etiquetas $\log \dot{M}$ de ISOSCELES. Proyectar las predicciones sobre la superficie CNO desplaza por tanto la distribución de $\log \dot{M}$ predicha respecto a la de la prueba sintética, aumentando W_1 . El mismo mecanismo que corrige T_{eff} , $\log g$ y R_* relocaliza $\log \dot{M}$ hacia FT26: es un intercambio controlado, consistente con la advertencia de §3.1 sobre el balance entre *dos prescripciones teóricas*, y no una falla del método.

W_1 de R_* es inestable (*scratch* $3.04 \rightarrow 3.39$; *domain* $\rightarrow 2.02$). R_* tiene el acoplamiento CNO más débil (coeficiente 1.44 frente a 16.81 de T_{eff}) y la menor muestra (148 frente a 184 estrellas), por lo que su distribución es la menos restringida y la más ruidosa entre semillas. La penalización explícita de *domain* la estabiliza; *scratch* sin ella deriva. Esto señala a R_* como el parámetro donde una restricción explícita adicional rinde mejor.

Costo in-distribution ($\sim 2\times$ en T_{eff} , $\sim 6\times$ en $\log g$, $\sim 3\times$ en $\log \dot{M}$). Es el impuesto de regularización. La prueba ISOSCELES comparte la distribución sintética, de modo que toda atracción hacia una prescripción externa debe costar ajuste in-distribution. El factor $6\times$ en $\log g$ es grande en términos relativos pero absoluto modesto ($0.013 \rightarrow \sim 0.08$), aún muy por debajo del MAE OOD de $\log g$ (0.25): la degradación in-distribution es pequeña frente a la ganancia OOD que compra.

5.4 Limitaciones

Cuatro limitaciones acotan el alcance de las conclusiones. Primero, $\mathcal{L}_{phys}$ mide *consistencia interna*, no validación independiente de $\dot{M}$: es el mismo término optimizado en entrenamiento y no disponemos de tasas de pérdida de masa observadas (los catálogos IACOB aportan sólo T_{eff} , $\log g$, R_*). Una validación genuina requeriría $\dot{M}$ medido

(anchura equivalente de $H\alpha$, exceso radio/IR), que dejamos como trabajo futuro. Segundo, las muestras observadas son pequeñas y heterogéneas: UVES POP O aporta sólo 12 estrellas —lo que vuelve ruidosas las estimaciones de W_1 , en especial R_* sobre 148 estrellas— e IACOB combina dos *pipelines* distintos (Holgado et al. [7] y de Burgos et al. [4]), imponiendo un piso de ruido en las etiquetas. Tercero, el método *hereda el dominio de FT26*: la restricción es válida sólo para $T_{\text{eff}} \in [30, 50]$ kK, $\log g \in [2.9, 4.3]$ y $R_* \in [7, 70] R_\odot$, y no puede extrapolarse a tipos B/A ni a Wolf-Rayet; la propia métrica de admisibilidad se define sobre estos límites. Cuarto, el modelo entrega estimaciones puntuales sin cuantificación de incertidumbre; una cabeza bayesiana —que Ortiz et al. [9] reservan como trabajo futuro— daría barras de error calibradas, particularmente relevantes en el régimen de alta varianza de R_* y $\log \dot{M}$.

6 Conclusiones

Investigamos si una restricción física suave, derivada de la prescripción CNO de Figueroa-Tapia et al. [5], reduce la brecha sintética en la estimación de parámetros de estrellas de tipo O a partir de perfiles $H\alpha$, sin acceso a etiquetas observadas durante el entrenamiento. La respuesta es afirmativa y cuantitativamente robusta: el término físico reduce el MAE de T_{eff} sobre IACOB de $\sim 10\,300$ a $\sim 3\,500$ K, revierte un sesgo sistemático de $+10\,000$ a $\sim -2\,300$ K, y baja la fracción de predicciones fuera del rango físico de 18.6% a 3.8% en T_{eff} y a $\sim 0\%$ en $\log g$ y R_* , a cambio de un costo in-distribution modesto. El efecto se localiza en el término físico mismo: es estable entre estrategias de activación (*ft*, *scratch*, *domain*) y —según el control con GradNorm (§4.7)— robusto al mecanismo de ponderación de gradientes, lo que descarta que dependa de un valor afortunado de λ_{phys} .

Los resultados negativos delimitan el alcance del método. La física observacional (*+obs*) no aporta señal adicional, porque la restricción opera sobre las *salidas* y no sobre la entrada; y la coherencia distribucional de $\log \dot{M}$ y R_* —los parámetros con menor acoplamiento CNO y menor muestra— no mejora de forma consistente. Las extensiones naturales son una validación independiente de $\dot{M}$ con observables de viento, kernels rotacionales realistas en la augmentación, una cabeza bayesiana para incertidumbres calibradas, y el balanceo adaptativo de gradientes como mecanismo de ponderación por defecto.

7 Declaración de uso de IA

Este informe fue elaborado con asistencia de Claude (Anthropic, modelos Opus 4.6–4.8). La herramienta se utilizó para: (i) apoyar la redacción y revisión de prosa en distintas secciones, mejorando claridad y estructura; (ii) discutir el posicionamiento del trabajo respecto al estado del arte; y (iii) asistir en la implementación de código experimental —incluida la variante de balanceo adaptativo GradNorm— y de los *scripts* de análisis y generación de figuras, bajo dirección de los autores. La pregunta de investigación, la hipótesis, las decisiones de diseño experimental y la interpretación de los resultados fueron desarrolladas por los estudiantes, quienes verificaron todo el contenido técnico y numérico. Las referencias fueron revisadas manualmente y contrastadas con los artículos originales.

References

- [1] Manuel Ballester, Santiago Lopez-Tapia, Seth Gossage, Patrick Koller, Philipp M. Srivastava, Ugur Demir, Yongseok Jo, Almudena P. Marquez, Christoph Wuersch, Souvik Chakraborty, et al. 2026. Learning the Stellar Structure Equations via Self-supervised Physics-Informed Neural Networks. *arXiv preprint arXiv:2604.06255* (2026).
- [2] Zhao Chen, Vijay Badrinarayanan, Chen-Yu Lee, and Andrew Rabinovich. 2018. GradNorm: Gradient normalization for adaptive loss balancing in deep multitask networks. In *International conference on machine learning*. PMLR, 794–803.
- [3] Vojtěch Cvrček, Martino Romaniello, Radim Šára, Wolfram Freudling, and Pascal Ballester. 2025. Stellar parameter prediction and spectral simulation using machine learning—A systematic comparison of methods with HARPS observational data. *Astronomy & Astrophysics* 693 (2025), A256.
- [4] Abel de Burgos, Sergio Simón-Díaz, Miguel A Urbaneja, and Joachim Puls. 2024. The IACOB project-X. Large-scale quantitative spectroscopic analysis of Galactic luminous blue stars. *Astronomy & Astrophysics* 687 (2024), A228.
- [5] F. Figueroa-Tapia, J. A. Panei, M. Curié, I. Araya, S. Ekström, A. C. Gormaz-Matamala, R. O. Venero, and L. S. Cidale. 2026. New self-consistent theoretical descriptions for mass-loss rates of O-type stars. *Astronomy & Astrophysics* 707 (2026), A196.
- [6] Kaiming He, Xiangyu Zhang, Shaoqing Ren, and Jian Sun. 2016. Deep residual learning for image recognition. In *Proceedings of the IEEE conference on computer vision and pattern recognition*. 770–778.
- [7] G. Holgado, S. Simón-Díaz, and A. Herrero. 2025. The IACOB project-XV. Updated calibrations of fundamental parameters of Galactic O-type stars. *Astronomy & Astrophysics* 703 (2025), A175.
- [8] Núria Masclans, Fernando Vázquez-Novoa, Marc Bernades, Rosa M. Badia, and Lluís Jofre. 2023. Thermodynamics-informed neural network for recovering supercritical fluid thermophysical information from turbulent velocity data. *International Journal of Thermofluids* 20 (2023), 100448.
- [9] Felipe Ortiz, Raquel Pezoa, Michel Cure, Ignacio Araya, Roberto O. Venero, Catalina Arcos, Pedro Escárate, Natalia Machuca, and Alejandra Christen. 2025. A multi-stage machine learning-based method to estimate wind parameters from $H\alpha$ lines of massive stars. *Astronomy and Computing* 52 (2025), 100941.
- [10] Teaghan O’Brian, Yuan-Sen Ting, Sébastien Fabbro, Kwang M. Yi, Kim Venn, and Spencer Bialek. 2021. Cycle-StarNet: bridging the gap between theory and data by leveraging large data sets. *The Astrophysical Journal* 906, 2 (2021), 130.
- [11] Jorick S. Vink, Alex de Koter, and Henney JGLM Lamers. 2000. New theoretical mass-loss rates of O and B stars. *arXiv preprint astro-ph/0008183* (2000).
- [12] Laura Von Rueden, Sebastian Mayer, Katharina Beckh, Bogdan Georgiev, Sven Giesselbach, Raoul Heese, Birgit Kirsch, Julius Pfommer, Annika Pick, Rajkumar Ramamurthy, et al. 2021. Informed machine learning—a taxonomy and survey of integrating prior knowledge into learning systems. *IEEE Transactions on Knowledge and Data Engineering* 35, 1 (2021), 614–633.